



CENTRO UNIVERSITÁRIO SANTO AGOSTINHO- UNIFSA
PRÓ-REITORIA DE ENSINO
NÚCLEO DE APOIO PEDAGÓGICO-NUAPE
COORDENAÇÃO DO CURSO DE ENGENHARIA DE SOFTWARE
DISCIPLINA: ANÁLISE AVANÇADA DE DADOS
PROFA: MA. HELOISA GUIMARÃES

Investigação Estatística, Probabilística e Visual

Parte 1: Limpeza e Estruturação

Foco: Entendimento do Problema, Tipos de Dados e Sanitização.

- 1 **Exploração Inicial e Tipologia:** Carregue o dataset e identifique os tipos de dados (Nominal, Ordinal, Intervalar, Razão).
- 2 **Sanitização e Estatística Descritiva Inicial:**
 - Identifique e trate valores ausentes (Imputação por média/mediana ou exclusão?).
 - Detecte e trate duplicatas.
 - Corrija tipos de dados (ex: strings que deveriam ser floats).
- 3 **Detecção de Outliers:** Use métodos estatísticos (como o IQR - Intervalo Interquartilico) para identificar valores extremos que podem distorcer sua análise.
- 4 **Entrega 1:** Um DataFrame limpo e um breve relatório técnico documentando o que foi "consertado".

Parte 2: Análise Estatística, Probabilística e Visual

Foco: Análise Univariada, Bivariada, Probabilidade e Visualização.

Para as variáveis principais do seu dataset, realize as seguintes análises:

- 5 **Análise Univariada (Medidas de Tendência Central, Dispersão e Forma):**

- **Tendência Central:** Calcule Média, Mediana e Moda. Explique qual delas melhor representa o "centro" dos seus dados e por quê.
- **Dispersão:** Calcule Variância, Desvio Padrão e Amplitude. O quão "espalhados" estão seus dados?
- **Forma:** Calcule a **Assimetria (Skewness)** e a **Curtose (Kurtosis)**. Sua distribuição é normal? É alongada para a direita ou esquerda? É muito "pontuda" ou "achatada"?
- **Visualização:** Crie Histogramas e Boxplots que demonstrem essas medidas de forma clara.

6 Probabilidade em Análise de Dados:

- **Conceitos e Aplicações:** Calcule a probabilidade de ocorrência de um evento de interesse (ex: Probabilidade de Churn, Probabilidade de um imóvel custar mais que X).
- **Probabilidade Condicional:** Calcule a probabilidade de um evento dado outro (ex: Qual a probabilidade de Churn dado que o contrato é mensal?).

7 Análise Bivariada (Conexões e Correlações):

- **Correlação:** Calcule o coeficiente de **Pearson** (para relações lineares) e **Spearman** (para relações não lineares/ordinais).
- **Associação:** Como uma variável categórica influencia uma numérica? (Ex: O preço muda conforme o bairro?).

8 Visualização de Dados e Tipologia de Gráficos:

- **Seleção Baseada no Objetivo:** Escolha o gráfico correto para cada análise (Comparação, Distribuição, Relação).
- **Princípios de Percepção Visual e Design de Informação:** Aplique os princípios de **Tufte** (Data-Ink Ratio), **Gestalt** e a **Hierarquia de Cleveland e McGill** em todos os gráficos.

9 Relatório Final de Insights:

- Não apenas mostre números. Explique o que eles significam para o problema de negócio.

Datasets

#	Dataset (Link Kaggle)
1	Telco Customer Churn
2	NYC Airbnb Open Data
3	Brazilian E-Commerce (Olist)
4	World Happiness Report
5	Ames Housing Dataset
6	LendingClub Loan Data
7	Used Cars Dataset (eBay)
8	Google Play Store Apps
9	Health Care Diabetes
10	Global Shark Attacks